

# Detecção de Intrusões com Explainable AI (XAI)

(SHAP e LIME)

**Autores: Antonio Francisco e Maurício Beutler.**



# CONTEXTO



## AMEAÇAS

Crescimento exponencial das ameaças cibernéticas em ambientes conectados.



## IDS

Sistemas de Detecção de Intrusão são essenciais para a defesa.



## CAIXA-PRETA

ML melhora a detecção, mas cria modelos opacos que exigem explicações confiáveis.



# PROBLEMA

## OPACIDADE

Modelos avançados detectam intrusões com precisão, mas falham em explicar o "porquê", criando uma lacuna de confiança.

## FALTA DE PADRÃO

Ferramentas de XAI divergem entre si e falta padronização para validar explicações, comprometendo decisões em SOC's.



# MOTIVAÇÃO

- 🕒 **-66% no tempo de análise:** XAI agiliza drasticamente a triagem em SOCs.
- ★ **Confiança 4,5/5:** Analistas confiam mais em sistemas que explicam suas decisões.
- 🗣️ **Entendimento Profundo:** Entender a causa raiz é tão crítico quanto a detecção em si.





# JUSTIFICATIVA

## CONFLITO DE EXPLICAÇÕES

SHAP e LIME frequentemente produzem explicações divergentes para a mesma predição.

## IMPACTO NA SEGURANÇA

É crucial entender como essas diferenças afetam a resposta a incidentes e validar a interpretabilidade real dos modelos.



---

# OBJETIVO GERAL

Criar um fluxo de detecção de intrusões interpretável usando XGBoost + SHAP + LIME.



# OBJETIVOS ESPECÍFICOS

-  Pré-processar o dataset NSL-KDD para adequação ao modelo.
-  Treinar e otimizar um classificador XGBoost robusto.
-  Implementar técnicas de XAI (SHAP e LIME) no pipeline.
-  Comparar as explicações geradas e avaliar suas divergências.



# METODOLOGIA

## 1. COLETA

Pré-processamento dos dados brutos

## 2. MODELAGEM

Construção do XGBoost

## 3. XAI

Implementação de SHAP e LIME

## 4. ANÁLISE

Comparação e Validação



# DATASET (NSL-KDD)

**Versão Revisada:** Melhoria do KDD Cup 99 com remoção de duplicatas.

**Limpeza:** Remoção da coluna "difficulty" irrelevante.

**Encoding:** Transformação de variáveis categóricas via Label Encoding.

**Classes:** Agrupamento binário: Normal (0) vs Ataque (1).






# CLASSIFICADOR XGBOOST

Modelo altamente eficiente para dados tabulares estruturados.

## DESAFIOS & SOLUÇÕES

- **Desbalanceamento:** Tratado com parâmetro `scale_pos_weight`.
- **Validação:** Divisão estratificada Treino/Teste (70/30).






# XAI: SHAP

## TEORIA DOS JOGOS

Baseado em valores de Shapley, oferece uma análise consistente atribuindo a cada feature sua contribuição marginal.

Permite tanto análise **global** quanto **local**, ideal para identificar a "causa raiz" das decisões do modelo.





# XAI: LIME

## APROXIMAÇÃO LOCAL

Gera explicações perturbando os dados ao redor da instância e ajustando um modelo linear simples.

Gera regras **intuitivas** e rápidas para triagem, mas pode apresentar instabilidade em dados altamente correlacionados.





# | VALIDAÇÃO



## CONSISTÊNCIA

Avaliação da concordância entre as features apontadas pelo SHAP e LIME.



## DIREÇÃO

Verificação da coerência no impacto (positivo ou negativo) das features.



## PLAUSIBILIDADE

Validação com conhecimento de domínio de segurança cibernética.



# RESULTADOS: DESEMPENHO

0.99

F1 SCORE GERAL

0.99

RECALL DE ATAQUES

Apenas 18 ataques não detectados com baixo índice de falsos positivos.




# RESULTADOS: SHAP

## FEATURE DOMINANTE

`dst_host_srv_serror_rate`

Esta feature está fortemente relacionada a ataques do tipo **SYN Flood**. O SHAP forneceu uma explicação técnica consistente, apontando corretamente o motivo raiz do ataque.





# RESULTADOS: LIME

## REGRAS SIMPLES

Principais regras identificadas: `protocol_type` e `dst_bytes`.

O LIME gerou uma explicação mais acessível, focando nos **sintomas** observáveis em vez da causa raiz estrutural, mas mostrou instabilidade devido à multicolinearidade.






# MULTICOLINEARIDADE

O dataset possui grupos de features altamente correlacionados.

**XGBoost:** Escolhe arbitrariamente uma feature dominante.

**SHAP:** Respeita essa escolha, mantendo consistência.

**LIME:** Perde as relações naturais dos dados, resultando em instabilidade nas explicações locais.





# CONCLUSÃO

- ✓ **Eficácia:** XGBoost foi altamente eficaz na detecção.
- ✓ **Robustez:** SHAP provou-se mais robusto e fiel ao comportamento do modelo.
- ! **Limitação:** LIME é útil para triagem rápida, mas limitado em dados complexos.
- 📦 **Melhor Abordagem:** Combinar SHAP + LIME reforça a auditabilidade e a confiança nos sistemas de IDS.



# OBRIGADO!

Dúvidas?

Programa de Pós-Graduação em Engenharia de Software – UNIPAMPA